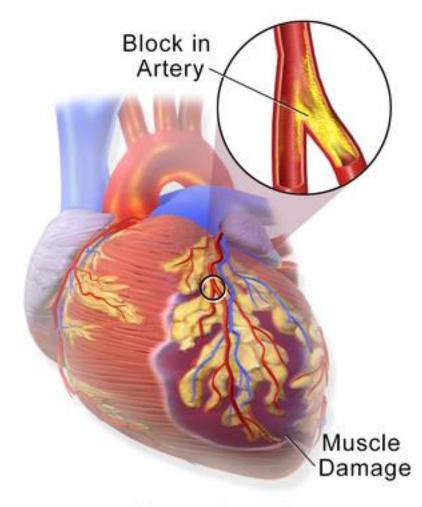


# KSU Mühendislik ve Mimarlık Fakültesi Bilgisayar Mühendisliği

Semih ACAR

Adem YETER

#### Kalp krizi Nedir?



**Heart Attack** 

**Kalp** damarındaki plakların aniden yırtılması ve üzerine pıhtı oturması ile **kalp** damarı aniden tıkanabilir, sonuçta **kalp** kası oksijensiz kalır. Oksijensiz kalan **kalp** kası hücreleri bir süre sonra ölmeye başlar.

#### Projenin amacı

 Çalışmanın amacı, hastanın yaş, cinsiyet, göğüs ağrısı tipi, kan basıncı ve kolesterol gibi verilerinden faydalanarak kalp krizi riskini tahmin etmek ve analizde bulunmaktır.

#### Kalp krizi veri seti

- Age : Age of the patient
- Sex : Sex of the patient
- exang: exercise induced angina (1 = yes; 0 = no)
- ca: number of major vessels (0-3)
- cp : Chest Pain type chest pain type
  - Value 1: typical angina
  - Value 2: atypical angina
  - Value 3: non-anginal pain
  - Value 4: asymptomatic

Yaş bilgisi

Cinsiyet bilgisi

Egzersize bağlı göğüs ağrısı

Florosopi ile renklendirilen

büyük kapların sayısı

Göğüs ağrısı tipleri:

- 1- Tipik angina pektoris.
- 2- Atipik angina pektoris.
- 3- Angina dışı göğüs ağrısı.
- 4- Asemptomatik

#### Kalp krizi veri seti

- trtbps : resting blood pressure (in mm Hg)
- chol: cholestoral in mg/dl fetched via BMI sensor
- fbs: (fasting blood sugar > 120 mg/dl) (1 = true; 0 = false)
- rest\_ecg: resting electrocardiographic results
  - Value 0: normal
  - Value 1: having ST-T wave abnormality (T wave inversions and/or ST elevation or depression of > 0.05 mV)
  - Value 2: showing probable or definite left ventricular hypertrophy by Estes' criteria
- thalach: maximum heart rate achieved
- target: 0= less chance of heart attack 1= more chance of heart attack

Dinlenme kan basıncı
Serum kolestoral
Açlık kan şekeri
İstirahat elektrokardiyografik
sonuçları

Maksimum kalp atış hızı

0= daha az kalp krizi geçirme

şansı 1= daha fazla kalp krizi
geçirme şans

data - DataFrame

Index	age	sex	cn	trtbos	chol	fbs	resteca	thalachh	exna	oldneak	sln	саа	thall	output	
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	1	
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2	1	
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2	1	
3	56	1	1	120	236	0	1	178	0	0.8	2	0	2	1	
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2	1	
5	57	1	0	140	192	0	1	148	0	0.4	1	0	1	1	
6	56	0	1	140	294	0	0	153	0	1.3	1	0	2	1	
7	44	1	1	120	263	0	1	173	0	0	2	0	3	1	
8	52	1	2	172	199	1	1	162	0	0.5	2	0	3	1	
9	57	1	2	150	168	0	1	174	0	1.6	2	0	2	1	
10	54	1	0	140	239	0	1	160	0	1.2	2	0	2	1	
11	48	0	2	130	275	0	1	139	0	0.2	2	0	2	1	
12	49	1	1	130	266	0	1	171	0	0.6	2	0	2	1	
13	64	1	3	110	211	0	0	144	1	1.8	1	0	2	1	
14	58	0	3	150	283	1	0	162	0	1	2	0	2	1	
15	50	0	2	120	219	0	1	158	0	1.6	1	0	2	1	
16	58	0	2	120	340	0	1				1	/ 11		_	ш
17	66	0	3	150	226	0		ata:	= pc	ı.rea		CSV(	nea	rt.cs\	<b>/</b> ")

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 303 entries, 0 to 302
Data columns (total 14 columns):
               Non-Null Count Dtype
     Column
               303 non-null
                                int64
 0
     age
                                int64
               303 non-null
     sex
                303 non-null
                                int64
     ср
                                int64
     trtbps
                303 non-null
     chol
                303 non-null
                                int64
 4
     fbs
                                int64
                303 non-null
                                int64
     restecg
               303 non-null
     thalachh
               303 non-null
                                int64
                                int64
                303 non-null
     exng
                                float64
     oldpeak
                303 non-null
                                int64
     slp
                303 non-null
               303 non-null
                                int64
     caa
     thall
                303 non-null
                                int64
                303 non-null
     output
dtypes: float64(1), int64(1 data.info
memory usage: 33.3 KB
```

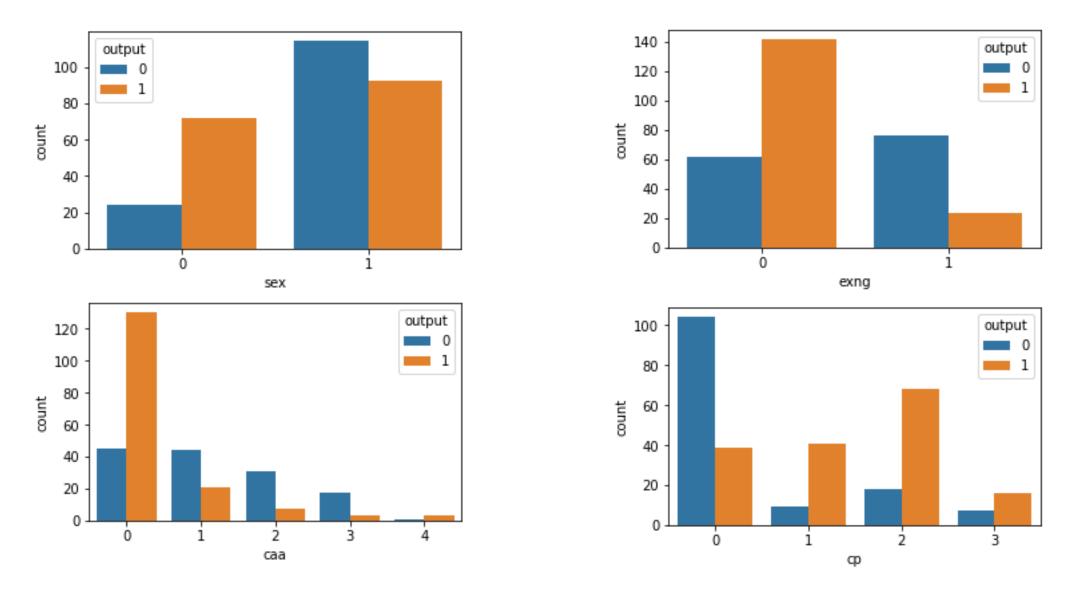
```
In [4]: data.shape
Out[4]: (302, 14)
```

output : 2

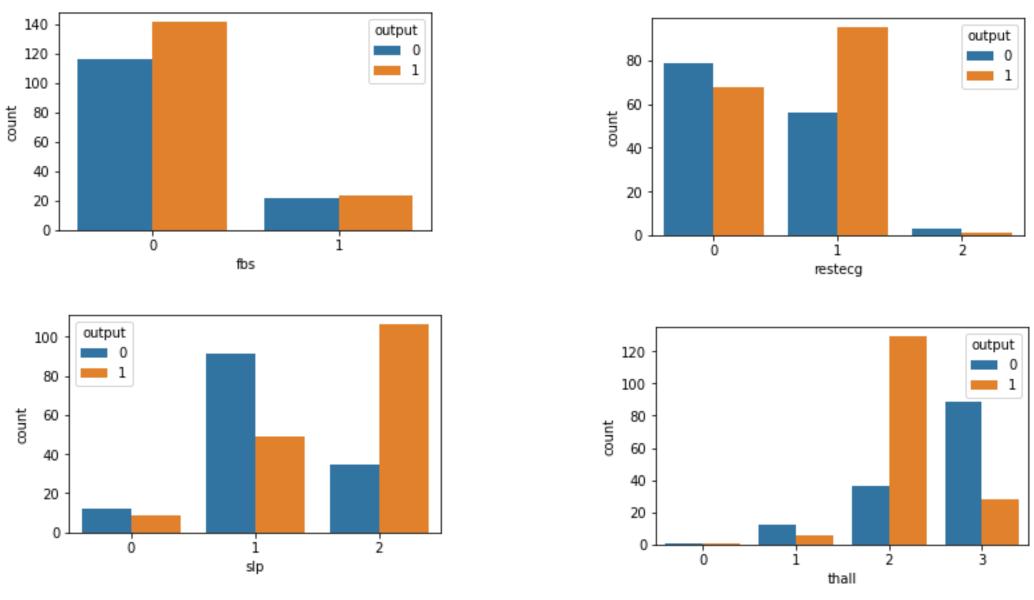
```
data.describe()
                                                                 thall
                                                                             output
             age
                          sex
                                                       caa
       302.00000
                  302.000000
                               302.000000
                                                302.000000
                                                                         302.000000
                                                             302.000000
count
        54.42053
                    0.682119
                                 0.963576
                                                  0.718543
                                                              2.314570
                                                                           0.543046
mean
std
         9.04797
                    0.466426
                                 1.032044
                                                  1.006748
                                                              0.613026
                                                                           0.498970
min
        29.00000
                    0.000000
                                 0.000000
                                                  0.000000
                                                              0.000000
                                                                           0.000000
25%
        48.00000
                    0.000000
                                 0.000000
                                                                           0.000000
                                                  0.000000
                                                              2.000000
50%
        55.50000
                    1.000000
                                 1.000000
                                                  0.000000
                                                              2.000000
                                                                           1.000000
75%
        61.00000
                    1.000000
                                 2.000000
                                                  1.000000
                                                              3.000000
                                                                           1.000000
                                                  4.000
        77.00000
                    1.000000
                                 3.000000
max
                                                       data.describe()
[8 rows x 14 columns]
```

```
age : 41
                ### benzersiz değer sayısı
sex : 2
cp: 4
                sutunlar = data.columns
trtbps: 49
chol: 152
                for sutun in sutunlar:
fbs : 2
restecg: 3
                   print(
thalachh : 91
exng: 2
                       sutun,":",
oldpeak: 40
                       len(data[sutun].unique())
slp:3
caa : 5
thall: 4
```

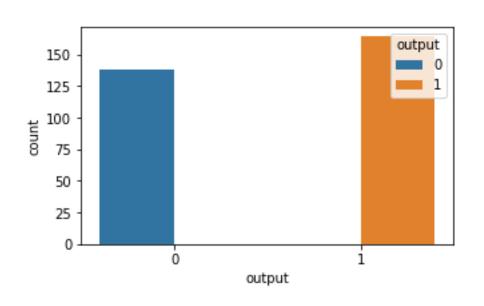
### Kategorik olan verilerin grafikleri



## Kategorik olan verilerin grafikleri

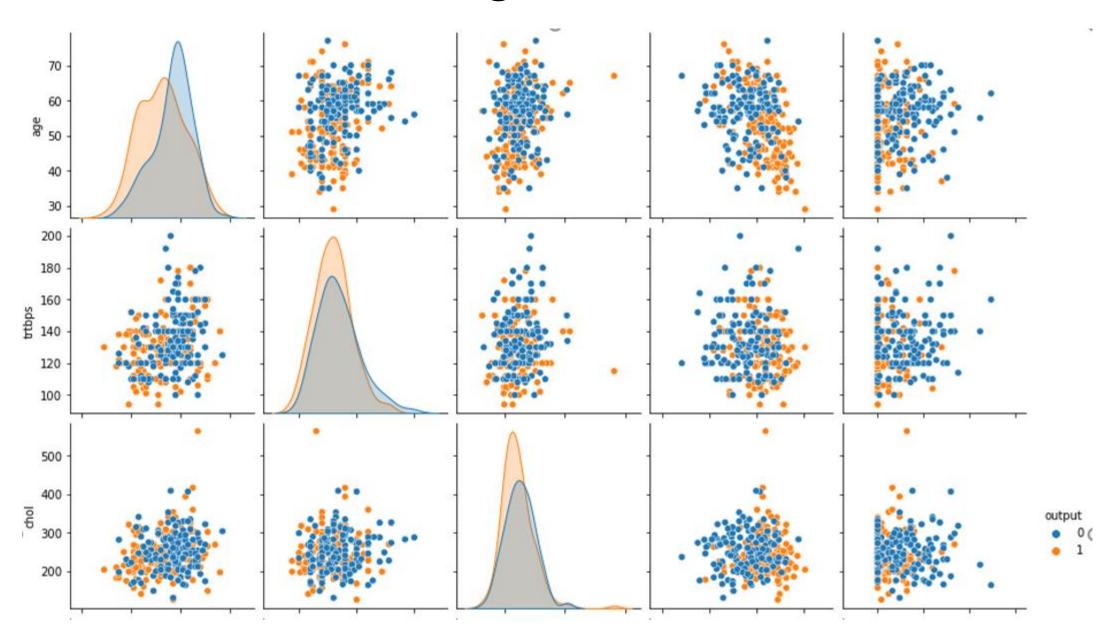


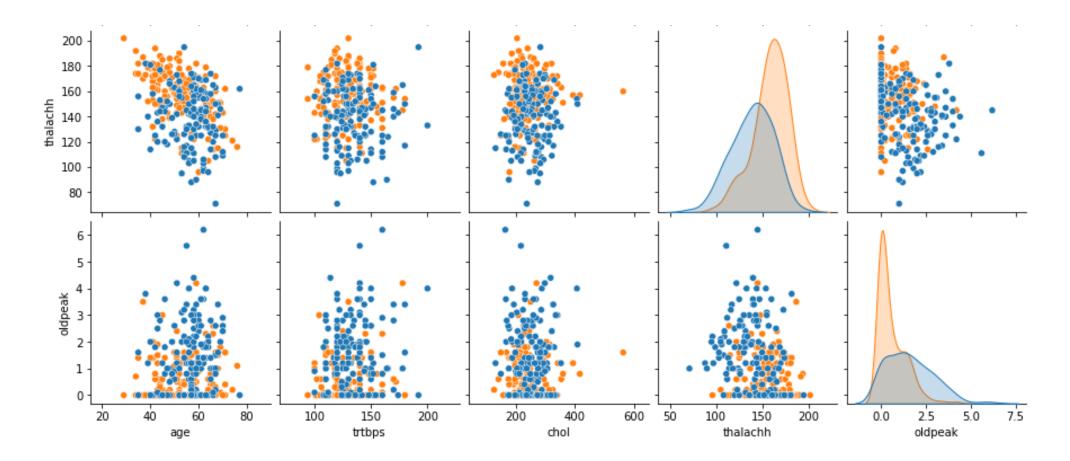
#### Kategorik olan verilerin grafikleri



```
### Kategorik olan verilerin grafikleri
kategorik sutunlar = [
   'sex','exng','caa',
   'cp','fbs','restecg',
   'slp','thall', 'output'
for sutun in kategorik sutunlar:
  plt.figure(figsize=(5,3))
  sns.countplot(
       x=sutun,
       data=data[kategorik sutunlar],
       hue="output"
```

## Devamlılık gösteren sütunlar

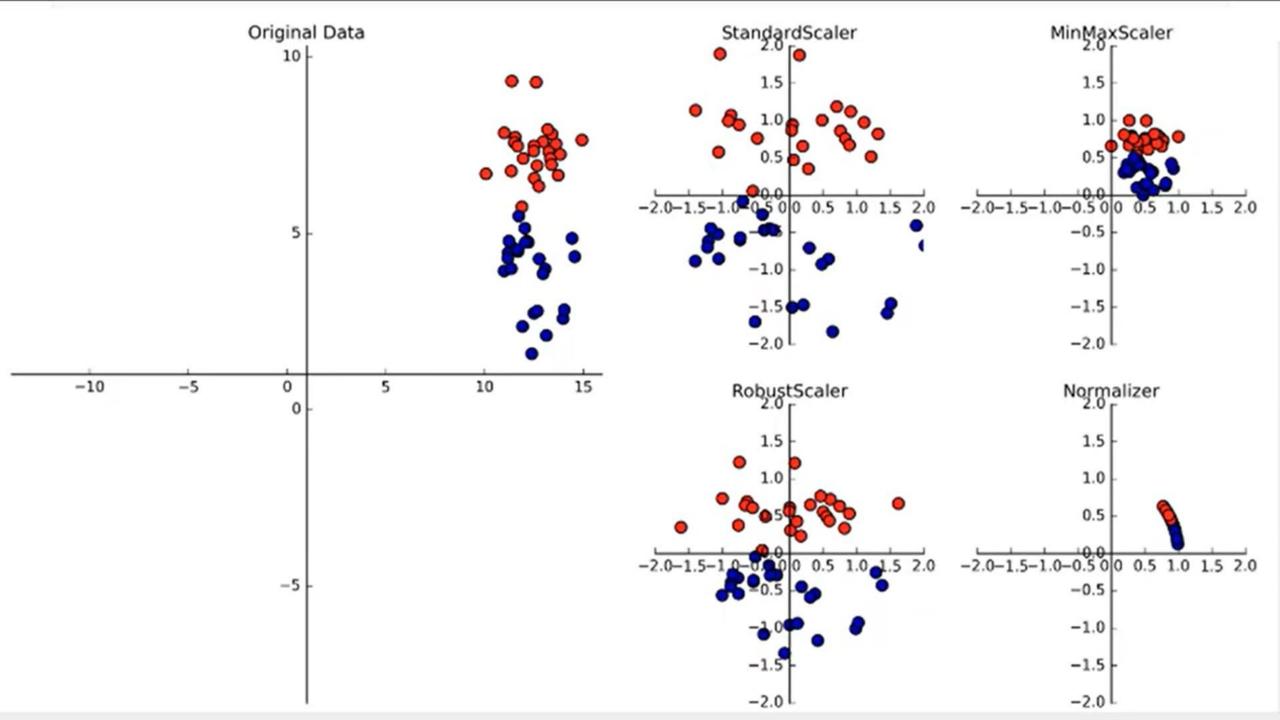




## pair plot
kategorik\_olmayan =
["age","trtbps","chol","thalachh","oldpeak","output"]
sns.pairplot(data[kategorik\_olmayan], hue="output")

#### Veri ölçeklendirme

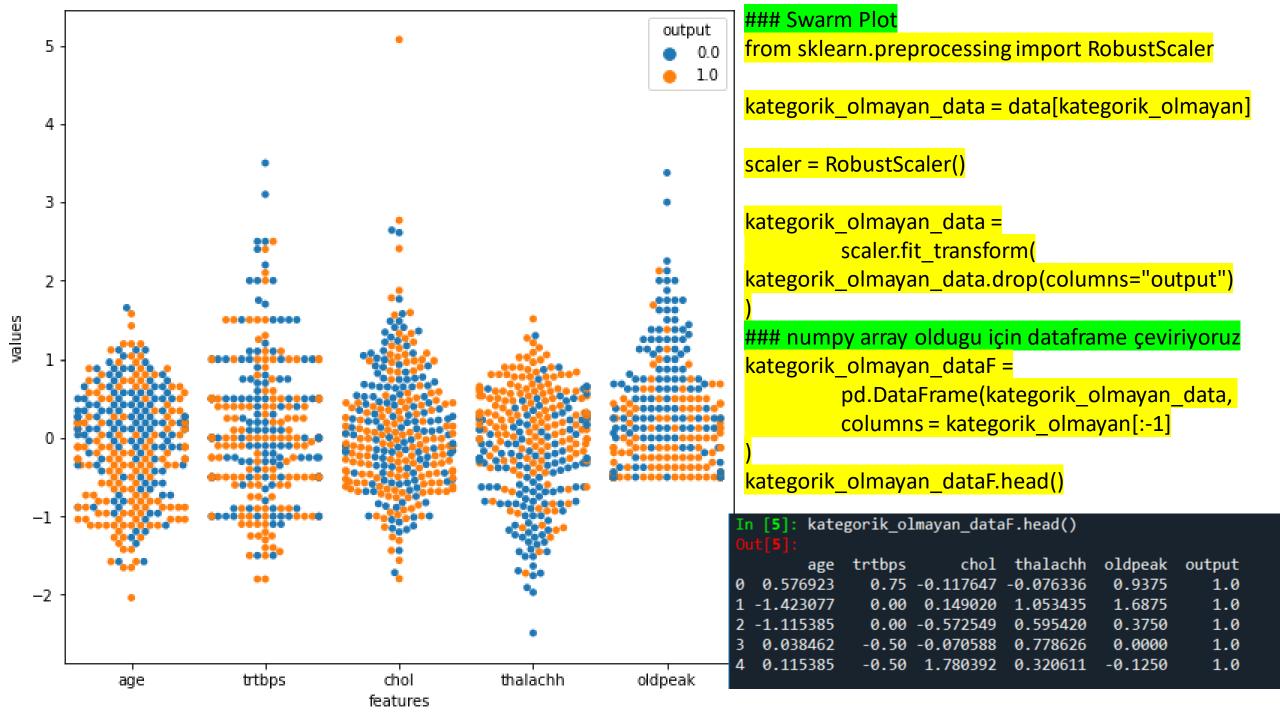
- Ölçekleme zorunlu değildir, yukarıdaki gibi ölçeklenmemiş bir data ile çok kötü bir sonuç alabiliriz.
- Ölçeklemenin temel amacı, daha büyük sayısal aralıkların etkilerinden kaçınmaktır
- Makine öğrenimi algoritmalarından önce verileri ölçeklendirmek daha iyi performans gösterecektir



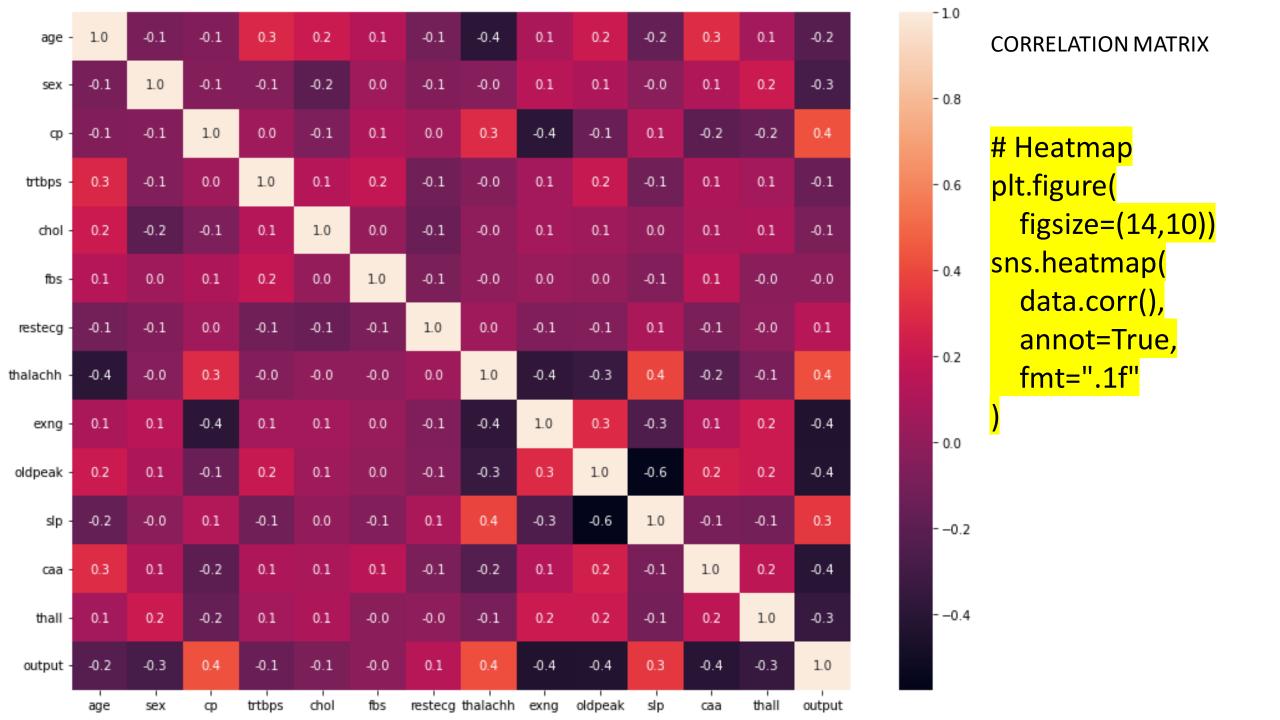
#### Robust Scaler

- RobustScaler, medyan tabanlı bir ölçekleme yöntemidir.
- RobustScaler formülü (Xi-Xmedian) / Xiqr olduğundan aykırı değerlerden etkilenmez.

$$X_{new} = \frac{X - X_{median}}{IQR}$$



```
output
                                                                          kategorik_olmayan_dataF =
                                                                                    pd.concat([kategorik_olmayan_dataF,
                                                                          data.loc[:, "output"]], axis = 1)
                                                                          kategorik_olmayan_dataF.head()
                                                                          kategorik_olmayan_dataF_melt = pd.melt(
                                                                               kategorik_olmayan_dataF,
   2
                                                                               id_vars="output",
                                                                               var_name="features",
values
                                                                               value name="values«
                                                                           kategorik_olmayan_dataF_melt.head()
                                                                          plt.figure(figsize=(8,8))
                                                                          sns.swarmplot(
                                                                               x="features",
                                                                               y="values",
  -2
                                                                               data=kategorik_olmayan_dataF_melt,
                                                                               hue="output«
                       trtbps
                                      chol
                                                               oldpeak
                                                 thalachh
           age
                                    features
```



#### Dummy (Kukla) Variable

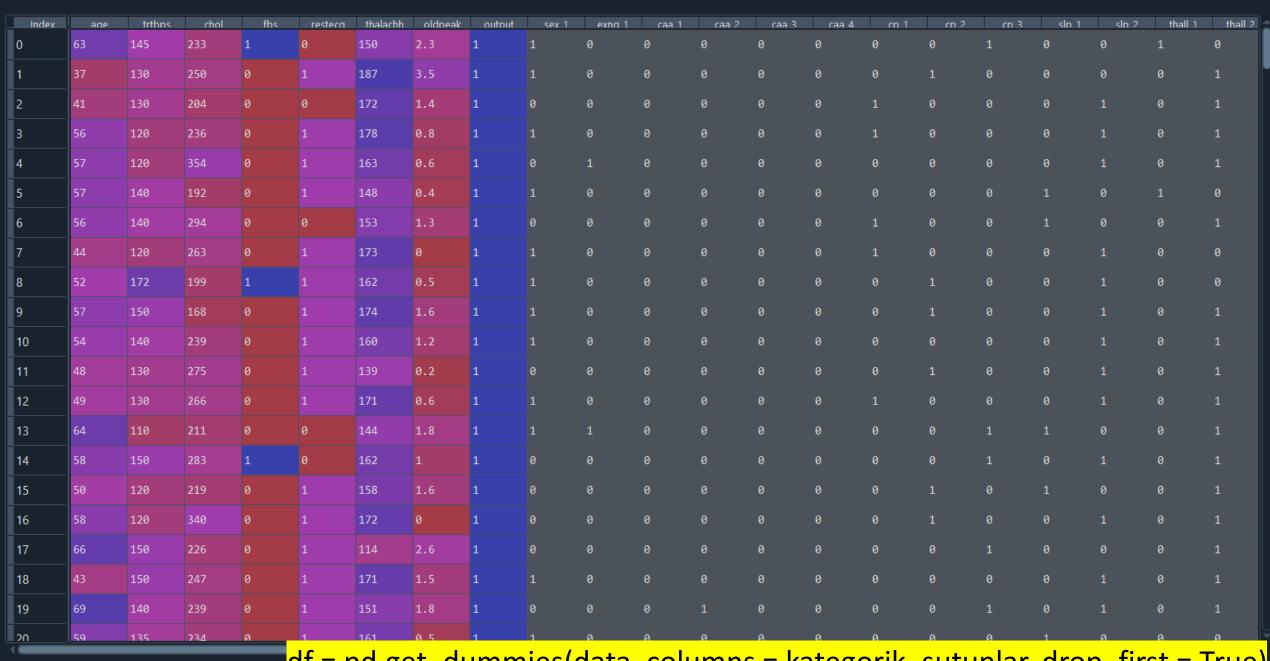
•Integer Encoding: Veride yer alan gruplara sayısal olarak bir değer ataması yapılır.

$${}^{\bullet}{A = 1, B = 2, C = 3}$$

•One-Hot Encoding: 1 ve 0 olarak dönüştürülen gruplar vektör dizeleri halinde yeni değişkenler oluştururlar.

•A, B, C birer değişkene çevrilerek; {A: [1,0,0], B: [0,1,0], C: [0,0,1]}



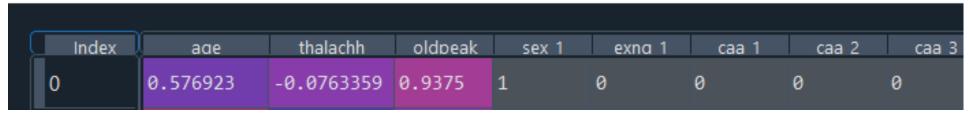


df = pd.get\_dummies(data, columns = kategorik\_sutunlar, drop\_first = True)

Format Resize ☑ Background color ☑ Column miliymus.

```
kategorik_sutunlar = ['sex','exng','caa','cp','slp','thall']
# Yaş, Maksimum kalp atış hızı, ST depresyonu
kategorik_olmayan = ["age","thalachh","oldpeak"]
# Dummy variable oluşturmak
df = pd.get_dummies(data, columns = kategorik_sutunlar, drop_first = True)

x = df.drop(columns=['output',"chol","trtbps","fbs",'restecg'])
y = df['output']
x[kategorik_olmayan] = scaler.fit_transform(x[kategorik_olmayan])
& x - DataFrame
```



```
from sklearn.model_selection import train_test_split
```

X\_train, X\_test, y\_train, y\_test = train\_test\_split(x,y, test\_size=0.2, random\_state=42)

```
print("X_train :",X_train.shape)
print("X_test :",X_test.shape)
print("y_train :",y_train.shape)
print("y_test :",y_test.shape)
```

```
X_train : (241, 17)
X_test : (61, 17)
y_train : (241,)
y_test : (61,)
```

#### K-en yakın komşu algoritması

from sklearn.neighbors import KNeighborsClassifier

```
## Öklid uzaklığı -- euclidean
ken = KNeighborsClassifier(n_neighbors=5, metric="euclidean")
ken.fit(X_train,y_train)

print("K-en yakın komşu algoritması: ",ken.score(X_test,y_test))

## Confusion Matrix

[[26 3]
[ 4 28]]
```

```
ken_prediction = ken.predict(X_test)
print(confusion_matrix(y_test, ken_prediction))
confusion_heatmap(ken_prediction,"K-en yakın komşu algoritması")
```

#### Karar ağaçları

from sklearn.tree import DecisionTreeClassifier

```
tree = DecisionTreeClassifier()
tree.fit(X_train,y_train)
```

print("Karar Ağaçları: ",tree.score(X\_test,y\_test))

```
## Confusion Matrix

decision_prediction = tree.predict(X_test)

print(confusion_matrix(y_test, decision_prediction))

confusion_heatmap(decision_prediction,"Karar Ağaçları")
```

```
Karar Ağaçları: 0.7704918032786885
[[25 4]
[10 22]]
```

#### Logistic regresyon

```
from sklearn.linear_model import LogisticRegression
logreg = LogisticRegression()
logreg.fit(X_train,y_train)
print("Logistic Regression: ",logreg.score(X_test,y_test))
## Confusion Matrix
logreg_prediction = logreg.predict(X_test)
print(confusion_matrix(y_test, logreg_prediction))
confusion_heatmap(logreg_prediction, "Logistic Regression")
```

```
Logistic Regression: 0.8852459016393442
[[26 3]
[ 4 28]]
```

#### Naive Bayes

from sklearn.naive\_bayes import GaussianNB

```
nb = GaussianNB()
nb.fit(X_train,y_train)
print("Naive Bayes:",nb.score(X_test,y_test))
```

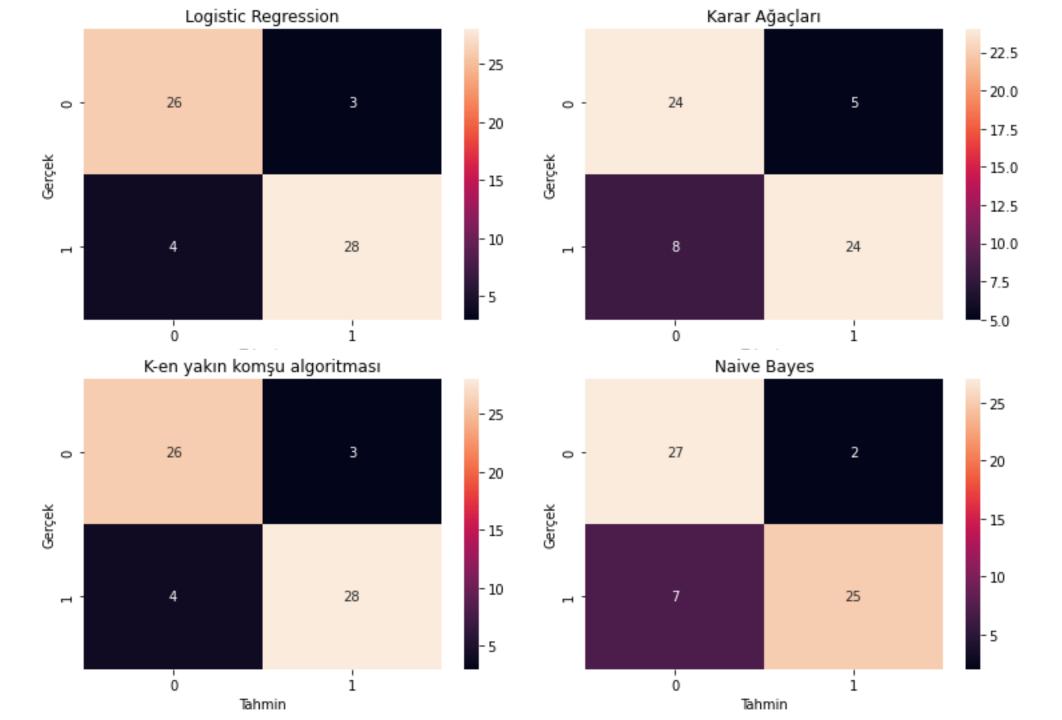
```
## Confusion Matrix
nb_prediction = nb.predict(X_test)
print(confusion_matrix(y_test, nb_prediction))
confusion_heatmap(nb_prediction,"Naive Bayes")
```

```
Naive Bayes: 0.8524590163934426
[[27 2]
[ 7 25]]
```

#### Confusion heatmap Fonksiyonu

def confusion\_heatmap(alg\_predict, title):

```
plt.figure()
sns.heatmap(confusion_matrix(y_test, alg_predict), annot=True)
plt.xlabel("Tahmin")
plt.ylabel("Gerçek")
plt.title(title)
```



#### Kaynak:

- Heart Attack Analysis & Prediction Dataset | Kaggle
- <u>scikit-learn: machine learning in Python scikit-learn 1.2.0 documentation</u>
- Scikit-Learn Kütüphanesi ile Data Ölçeklendirme | by İbrahim Halil Kaplan |
   Machine Learning Turkiye | Medium
- DENETİMSİZ ÖĞRENME | VERİ ÖLÇEKLEME | SCIKIT LEARN UYGULAMALARI
   PYTHON MAKİNE ÖĞRENMESİ DERSLERİ YouTube
- Veri Biliminde Kategorik Değişkenler, Dummy (Kukla) Variable ve Python Uygulaması | by Yiğit Şener | Medium
- K-NN (K-NEAREST NEİGHBORS) ALGORİTMASI İLE KALP KRİZİ TAHMİN VE ANALİZİ | by Fatma Çetin | Medium